

Data Engineering Project – Formula 1

FASE 2

DATA LAKE & ORCHESTRAZIONE

Pipeline incrementale e orchestrata per l'analisi dei dati storici del campionato mondiale di Formula 1



Made with GAMMA



L'Evoluzione dalla Fase 1 alla Fase 2

Fase 1: Pipeline Base

Ingestione batch statica con ricaricamento completo del dataset a ogni esecuzione. Approccio funzionale ma non scalabile in contesti reali.

Fase 2: Architettura Incrementale

Introduce Data Lake, ingestione incrementale, ledger di controllo, orchestrazione completa e scheduling automatico. Realismo architetturale vicino alla produzione.

Data Lake e Organizzazione dei Dati



Struttura del Data Lake

Implementato su filesystem locale utilizzando Parquet come formato colonnare ad alte prestazioni. I dati sono organizzati in batch giornalieri partizionati per data.

📁 **Formato:** data_lake/raw/dt=YYYY-MM-DD/

Ogni batch contiene races.parquet, results.parquet e altri file correlati

Il Data Lake diventa la fonte di verità della pipeline in Fase 2, garantendo tracciabilità e versionamento completo dei dati.

Ingestione Incrementale e Ledger

01

Lettura Batch Disponibili

La pipeline legge tutti i batch presenti nel Data Lake, identificando le partizioni temporali da processare

02

Confronto con Ledger

Verifica nel ledger (meta.processed_batches) quali batch sono già stati elaborati precedentemente

03

Processamento Selettivo

Processa esclusivamente i nuovi batch non ancora registrati, garantendo affidabilità e assenza di duplicati

04

Aggiornamento Tracciamento

Registra i batch processati nel ledger per future esecuzioni incrementali

Questo meccanismo garantisce efficienza computazionale e integrità dei dati in ogni esecuzione della pipeline.

Generazione Dati Sintetici

Simulazione Stagioni Future

Per rendere la pipeline realmente incrementale, è stato sviluppato uno script di generazione di stagioni sintetiche F1.

Nuove Stagioni

Creazione progressiva di stagioni 2025, 2026 e successive


Coerenza Realistica

Numero di gare e piloti allineato con stagioni reali

Randomizzazione

Punti e risultati generati in modo casuale ma plausibile

La generazione è implementata tramite Python + Polars, senza dipendenze esterne di simulazione.



Orchestrazione e Automazione



Bronze Layer

Ingestione incrementale dal Data Lake con ledger tracking



Silver Layer

Pulizia, standardizzazione e deduplicazione dati



Gold Layer

Modello analitico star schema pronto per dashboard

GitHub Actions

Esecuzione
schedulata
giornaliera tramite
cron automatico

Run Locale/Manuale

Possibilità di
esecuzione on-
demand per test e
debugging

Versionamento

DuckDB e batch
aggiornati
committati
automaticamente



Risultati e Valore Aggiunto

Miglioramenti Architeturali



Robustezza

Gestione errori, idempotenza e tracciamento completo delle esecuzioni



Automazione

Scheduling automatico e orchestrazione end-to-end senza intervento manuale



Realismo

Architettura incrementale vicina a scenari di produzione enterprise



Riproducibilità

Pipeline completamente versionata e deployabile in qualsiasi ambiente

Dashboard Live

La dashboard Streamlit rimane invariata e interroga il Gold layer aggiornato incrementalmente.

[Visualizza Dashboard](#)

Funzionalità Text-to-SQL opzionale tramite Google Gemini per query in linguaggio naturale.